Informe: Tarea 1 Aprendizaje Automático

Mateo Sebastián Mora Montero, Diego Carvajal González

Notación y convención de las pérdidas

Sea $\mathcal{D} = \{(\boldsymbol{x}_n, y_n)\}_{n=1}^N$, con $X \in \mathbb{R}^{N\times D}$, $\boldsymbol{w} \in \mathbb{R}^D$ e intercepto $b \in \mathbb{R}$. Las filas de X son observaciones. En regresión $y_n \in \mathbb{R}$; en clasificación binaria $y_n \in \{0, 1\}$.

$$\boldsymbol{z} = X\boldsymbol{w} + b\mathbf{1}_N, \qquad p_n = \sigma(z_n) = \frac{1}{1+e^{-z_n}}, \tag{1}$$

$$J_{\text{reg}}(\boldsymbol{w}, b) = \frac{1}{2N}\|\boldsymbol{z} - \boldsymbol{y}\|_2^2, \tag{2}$$

$$J_{\log}(\boldsymbol{w}, b) = -\frac{1}{N}\sum_{n=1}^{N}\big[y_n \log p_n + (1-y_n)\log(1-p_n)\big], \tag{3}$$

$$F(\boldsymbol{w}, b) = J(\boldsymbol{w}, b) + \lambda_1\|\boldsymbol{w}\|_1 + \frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2, \qquad \lambda_1, \lambda_2 \geq 0. \tag{4}$$

1 Problema 1. Mínimos cuadrados, Ridge y estabilidad

(a) Log-verosimilitud, gradiente, Hessiano y ecuaciones normales

Sea $z_n = \boldsymbol{w}^\top \boldsymbol{x}_n + b$. El modelo es $Y_n \mid \boldsymbol{x}_n \sim \mathcal{N}(z_n, \sigma^2)$, entonces

$$P(Y_n = y_n \mid X_n = \boldsymbol{x}_n) = \frac{1}{\sqrt{2\pi}\,\sigma}\, e^{-(y_n - z_n)^2/2\sigma^2}.$$

Por independencia condicional la verosimilitud es

$$L(\boldsymbol{w}, b) = \prod_{n=1}^{N} \frac{1}{\sqrt{2\pi}\,\sigma}\, e^{-(y_n - z_n)^2/2\sigma^2}.$$

Como log es estrictamente creciente, maximizar esto es lo mismo que maximizar $l(\boldsymbol{w}, b) := \log(L(\boldsymbol{w}, b))$:

$$\begin{aligned} l(\boldsymbol{w}, b) &= \sum_{n=1}^{N}\left[\log\left(\tfrac{1}{\sqrt{2\pi\sigma}}\right) - \frac{(y_n - z_n)^2}{2\sigma^2}\right] \\ &= N\log\left(\tfrac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{1}{2\sigma^2}\sum_{n=1}^{N}(y_n - z_n)^2. \end{aligned}$$

Maximizar esto equivale a minimizar $\frac{1}{2N}\sum_n (y_n - z_n)^2 = \frac{1}{2N}\|\boldsymbol{y} - \boldsymbol{z}\|_2^2 = J_{\text{reg}}$.
Ahora, tenemos que las filas de X son de la forma $\boldsymbol{x}_n^\top$, y haciendo $\tilde{x}_n = (1, \boldsymbol{x}_n^T), \theta = (b, \boldsymbol{w}^T)$, así,

$$\boldsymbol{z} = X\boldsymbol{w} + b\mathbf{1}_N = \begin{bmatrix}\langle \boldsymbol{x}_1, \boldsymbol{w}\rangle + b \\ \vdots \\ \langle \boldsymbol{x}_N, \boldsymbol{w}\rangle + b\end{bmatrix} = \begin{bmatrix}\langle \tilde{\boldsymbol{x}}_1, \theta\rangle \\ \vdots \\ \langle \tilde{\boldsymbol{x}}_N, \theta\rangle\end{bmatrix} = \tilde{X}\theta$$

Ahora, para Ridge, usamos $P = \text{diag}(0, 1, \ldots, 1)$ y $\lambda_1 = 0$,

$$\begin{aligned} F(\boldsymbol{w}, b) &= J_{\text{reg}} + \frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2 && \boldsymbol{w} \in \mathbb{R}^D \\ &= \frac{1}{2N}\|\boldsymbol{z} - \boldsymbol{y}\|_2^2 + \frac{\lambda_2}{2}\|P\boldsymbol{\theta}\|_2^2 && \boldsymbol{y}, \boldsymbol{z} \in \mathbb{R}^N, P \in \mathbb{R}^{D+1 \times D+1}, \theta \in \mathbb{R}^{D+1} \\ &= \frac{1}{2N}\|\widetilde{X}\boldsymbol{\theta} - \boldsymbol{y}\|_2^2 + \frac{\lambda_2}{2}\boldsymbol{\theta}^\top P\boldsymbol{\theta} && \widetilde{X} \in \mathbb{R}^{D+1 \times N} \end{aligned}$$

Entonces

$$\begin{aligned} \nabla_{\boldsymbol{\theta}} F(\boldsymbol{\theta}) &= \frac{1}{N}\widetilde{X}^\top(\widetilde{X}\boldsymbol{\theta} - \boldsymbol{y}) + \lambda_2 P\boldsymbol{\theta} \in \mathbb{R}^{D+1} \\ \nabla^2_{\boldsymbol{\theta}} F(\boldsymbol{\theta}) &= \frac{1}{N}\widetilde{X}^\top\widetilde{X} + \lambda_2 P \in \mathbb{R}^{D+1 \times D+1} \end{aligned}$$

Igualando $\nabla_{\boldsymbol{\theta}} F(\boldsymbol{\theta})$ a 0, y multiplicando por N, tenemos

$$\widetilde{X}^\top\widetilde{X}\boldsymbol{\theta} + N\lambda_2 P\boldsymbol{\theta} = \widetilde{X}^\top\boldsymbol{y} \quad \Longrightarrow \quad (\widetilde{X}^\top\widetilde{X} + N\lambda_2 P)\,\boldsymbol{\theta} = \widetilde{X}^\top\boldsymbol{y}$$

(b) Unicidad de OLS y Ridge; ortogonalidad del residuo

En OLS hay solución única si y solo si $\widetilde{X}^\top\widetilde{X}$ tiene rango completo.

En Ridge ($\lambda_2 > 0$), veamos que el Hessiano $\nabla^2 F$ es definido positivo. Esto garantiza unicidad de la solución. Sea $\boldsymbol{v} = (v_0, \boldsymbol{v}_1)^\top$ con $v_0 \in \mathbb{R}$, $\boldsymbol{v}_1 \in \mathbb{R}^D$:

$$\left\langle \boldsymbol{v}, \left(\tfrac{1}{N}\widetilde{X}^\top\widetilde{X} + \lambda_2 P\right)\boldsymbol{v} \right\rangle = \frac{1}{N}\|\widetilde{X}\boldsymbol{v}\|_2^2 + \lambda_2\|\boldsymbol{v}_1\|_2^2 \geq 0$$

Si $\lambda_2 > 0$ esto se anula solo si $\boldsymbol{v}_1 = 0 \in \mathbb{R}^{D+1}$ y $v_0 = 0$, así que F es convexa y tiene un solo punto que la minimiza, sin importar el rango de $\widetilde{X}^T\widetilde{X}$

Ortogonalidad del residuo. Sea $\boldsymbol{r} = \boldsymbol{y} - \widetilde{X}\boldsymbol{\theta}$.

En OLS, $\widetilde{X}^\top\widetilde{X}\boldsymbol{\theta} = \widetilde{X}^\top\boldsymbol{y}$, entonces

$$\widetilde{X}^\top\boldsymbol{r} = \widetilde{X}^\top\boldsymbol{y} - \widetilde{X}^\top\widetilde{X}\boldsymbol{\theta} = 0$$

Esto es, $\boldsymbol{r} \perp \text{col}(\widetilde{X})$, y $\boldsymbol{z}$ es la proyección otrogonal de $\boldsymbol{y}$ a $\text{col}(\widetilde{X})$

En Ridge,

$$\widetilde{X}^\top\boldsymbol{y} - \widetilde{X}^\top\widetilde{X}\boldsymbol{\theta} = N\lambda_2 P\boldsymbol{\theta} \neq 0 \quad \text{si } \boldsymbol{\theta} \neq (b, 0)$$

Entonces los residuos no son ortogonales a $\text{col}(\widetilde{X})$, y no hay proyección.

(c) Sesgo y varianza de Ridge

Fijamos $b = 0$, X fija de rango columna completo, $\boldsymbol{y} = X\boldsymbol{w}^\star + \boldsymbol{\varepsilon}$, $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I_N)$.

$$\begin{aligned} F(\boldsymbol{w}) &= \frac{1}{2N}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2 \\ \nabla F &= X^\top X\boldsymbol{w}/N - X^\top\boldsymbol{y}/N + \lambda_2\boldsymbol{w} \end{aligned}$$

El $\hat{\boldsymbol{w}}$ que maximiza F cumple que $X^\top\boldsymbol{y} = (X^\top X + N\lambda_2 I_d)\hat{\boldsymbol{w}}$. Escribimos $M = X^\top X + N\lambda_2 I_d$, que es simétrica, y como $\nabla^2 F$ es definida positiva, también es inverible. Luego:

$$\hat{\boldsymbol{w}} = M^{-1}X^T X\boldsymbol{w}^* + M^{-1}X^T\boldsymbol{\varepsilon}$$

$$\mathbb{E}[\hat{\boldsymbol{w}}] = \mathbb{E}[M^{-1}X^T X\boldsymbol{w}^* + M^{-1}X^T\boldsymbol{\varepsilon}] = M^{-1}X^T X\boldsymbol{w}^*$$
$$\mathrm{Cov}(\hat{\boldsymbol{w}}) = \mathrm{Cov}(M^{-1}X^T Xw^* + M^{-1}X^T\boldsymbol{\varepsilon}) = M^{-1}X^T\,\mathrm{Cov}(\boldsymbol{\varepsilon})XM^{-1} = \sigma^2 M^{-1}X^T XM^{-1}$$

Para el sesgo:

$$\mathbb{E}[\hat{\boldsymbol{w}}] - \boldsymbol{w}^\star = M_R^{-1}X^\top X\boldsymbol{w}^\star - \boldsymbol{w}^\star = (M_R^{-1}X^\top X - I_d)\boldsymbol{w}^\star = M^{-1}(X^T X - M)\boldsymbol{w}^* = -N\lambda_2 M^{-1}\boldsymbol{w}^*$$

$X^\top X$ es simétrica definida positiva (rango columna completo), entonces

$$X^\top X = V\,\mathrm{diag}(\mu_1,\ldots,\mu_D)V^\top, \qquad \mu_i > 0,\ V^\top V = I,$$

con vectores propios $\boldsymbol{v}_i$. Sea $\tau := N\lambda_2$, de modo que $M = X^\top X + \tau I_d$. Entonces $M = V\,\mathrm{diag}(\mu_i + \tau)V^\top$ y $M^{-1} = V\,\mathrm{diag}\left(\frac{1}{\mu_i+\tau}\right)V^\top$: toda matriz en las fórmulas es diagonal en la misma base. Sea $\alpha_i := \boldsymbol{v}_i^\top \boldsymbol{w}^\star$.

A lo largo de estas direcciones, tenemos que

$$\boldsymbol{v}_i^\top \mathbb{E}[\hat{\boldsymbol{w}}] = \frac{\mu_i}{\mu_i+\tau}\alpha_i, \qquad \mathrm{sesgo}_i = -\frac{\tau}{\mu_i+\tau}\alpha_i, \qquad \mathrm{Cov}(\hat{\boldsymbol{w}}) = \sigma^2 V\,\mathrm{diag}\left(\frac{\mu_i}{(\mu_i+\tau)^2}\right)V^\top,$$
$$\mathrm{Var}_i = \sigma^2\frac{\mu_i}{(\mu_i+\tau)^2}.$$

Ridge encoge la i-ésima coordenada de $\boldsymbol{w}^\star$ por el factor $\frac{\mu_i}{\mu_i+\tau} \in (0,1)$, y los errores en distintas direcciones propias son no correlacionados.

Al hacer tender λ_2 (τ) a 0 o inf, obtenemos lo siguiente:

	$\tau \to 0$ (OLS)	$\tau \to \infty$
sesgo_i	0	$-\alpha_i$ (así $\mathbb{E}\hat{\boldsymbol{w}} \to 0$)
Var_i	σ^2/μ_i	$\approx \sigma^2\mu_i/\tau^2 \to 0$

En $\tau = 0$ OLS es insesgado pero la varianza explota en las direcciones con μ_i pequeño (la inestabilidad que Ridge corrige). Cuando $\tau \to \infty$, $\hat{\boldsymbol{w}} \to 0$: no hay varianza, pero la estimación ignora los datos y el sesgo es todo $\boldsymbol{w}^\star$.

Cuando $\tau \to \infty$ el error tiende a $\|\boldsymbol{w}^\star\|^2$, mientras que OLS tiene error $\sigma^2\sum_i 1/\mu_i$. Si el ruido es pequeño (y los μ_i no son muy pequeños), $\|\boldsymbol{w}^\star\|^2 > \sigma^2\sum_i 1/\mu_i$: un τ grande tiene menos varianza que OLS pero mayor error.

2 Problema 2. Lasso, esparsidad y representación

(a) Caso ortogonal y umbral suave

Datos centrados, $b = 0$, $X^\top X/N = I_D$, $\boldsymbol{s} = X^\top\boldsymbol{y}/N$.

$$\begin{aligned}
F(\boldsymbol{w}) &= \frac{1}{2N}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda_1\|\boldsymbol{w}\|_1 \\
&= \frac{1}{2N}(X\boldsymbol{w} - \boldsymbol{y})^T(X\boldsymbol{w} - \boldsymbol{y}) + \lambda_1\|\boldsymbol{w}\| \\
&= \frac{1}{2N}(\boldsymbol{w}^\top X^\top X\boldsymbol{w} - \boldsymbol{w}^\top X^\top\boldsymbol{y} - \boldsymbol{y}^\top X\boldsymbol{w} + \boldsymbol{y}^\top\boldsymbol{y}) + \lambda_1\sum_j |w_j| \\
&= \tfrac{1}{2}\boldsymbol{w}^\top\boldsymbol{w} - \boldsymbol{w}^\top\boldsymbol{s} + \frac{1}{2N}\boldsymbol{y}^\top\boldsymbol{y} + \lambda_1\sum_j |w_j| \\
&= \sum_{j=1}^{D}\Big[\frac{w_j^2}{2} - w_j s_j + \lambda_1|w_j|\Big] + \frac{1}{2N}\boldsymbol{y}^\top\boldsymbol{y}
\end{aligned}$$

Minimizamos cada uno de los sumandos $F_j(w_j)$. Aunque $|\cdot|$ no es diferenciable, cada F_j es convexa, y usamos subdiferenciales ∂F. Un $\boldsymbol{w}^*$optimiza sii $0 \in \partial F$.

Si $|w_i| < 0$, $|w_i| = -1$, y $\partial F_i(w_i) = w_i - s_i - \lambda_1$, y por tanto

$$w_i^* = s_i + \lambda_1 = \text{sgn}(s_i)(|s_i| - \lambda_1) \quad (w_i < 0 \iff s_i < -\lambda_1 < 0)$$

Similarmente, si $w_i > 0$, entonces $w_i^* = s_i - \lambda_1 = \text{sgn}(s_i)(|s_i| - \lambda_1)$, y $w_i > 0 \iff s_i > \lambda_1$

Si $w_i = 0$, usamos que $\partial|0| = [-1, 1]$, y 0 es óptimo sii $0 \in \{-s_i + \lambda_1 t : t \in [-1, 1]\}$ sii $s_i \in [-\lambda_1, \lambda_1]$

Con esto, obtenemos que

$$w_i^* = \begin{cases} \text{sgn}(s_i)(|s_i| - \lambda_1) & |s_i| > \lambda_1 \\ 0 & |s_i| \leq \lambda_1 \end{cases} = \text{SoftThhreshold}_{\lambda_1}(s_i)$$

(b) Caso no ortogonal y columnas idénticas

Tenemos que $F(\boldsymbol{w}) = \frac{1}{2N}\|\boldsymbol{r}\|_2^2 + \lambda_1\|\boldsymbol{w}\|_1$ con $\boldsymbol{r} = X\boldsymbol{w} - \boldsymbol{y}$. De nuevo, usaremos subdiferenciales para optimizar esta función.

Usaremos también que si $f_i(w_i)$ son funciones convexas, y $f(\boldsymbol{w}) = (f_1(w_1), \cdots f_D(w_D))$, entonces $\partial f = \Pi_i \partial f_i$.

Con esto,

$$\partial F = \frac{1}{N} X^T \boldsymbol{r} + \lambda_1 \partial\|\boldsymbol{w}\|_1$$

Escribiendo x^j para la j-ésima columna de X, tenemos que

$$\boldsymbol{r} = \sum_{i=1}^{D} x^i w_i - \boldsymbol{y} = \sum_{i \neq i_0} x^i w_i - \boldsymbol{y} + x^{i_0} w_{i_0} =: \boldsymbol{r}_{-i_0} + x^{i_0} w_{i_0}$$

Expresando el subdiferencial en coordenadas, tenemos

$$\begin{aligned} (\partial F)_i &= \frac{1}{N}(x^i)^T \boldsymbol{r} + \lambda_1 \partial|w_i| && i+1, \cdots, D \\ &= -\frac{1}{N}(x^i)^T \boldsymbol{r}_i - \frac{1}{N}(x^i)^T x^i w_i + \lambda_1 \partial|w_i| \\ &= -\frac{1}{N}(x^i)^T \boldsymbol{r}_i - \frac{1}{N}\|x^i\|_2^2 w_i + \lambda_1 \partial|w_i| \\ &= -\beta_i - \alpha_i w_i + \lambda_1 \partial|w_i| \end{aligned}$$

Con esto, w_i^* es óptimo sii $\beta_i + \alpha_i w_i^* \in \lambda_1 \partial|w_i|$, y esto es análogo al caso anterior, donde solucionábamos $w_i - s_i \in \lambda_1 \partial|w_i|$. Por tanto

$$w_i^* = \frac{1}{\alpha_i} \text{SoftThreshold}_{\lambda_1}(\beta_i)$$

Ahora, supongamos que las primeras dos columnas x^1, x^2 de X son iguales, y que $w_1 + w_2 = s$. Por tanto

$$X\boldsymbol{w} = \sum_{i=1}^{D} x^i w_i = x^1(w_1 + w_2) + \sum_{i>2} x^i = x^1 s + \sum_{i>2} x^i w_i$$

Si $\boldsymbol{w}, \boldsymbol{w}'$ son dos vectores en $\mathbb{R}^D$ con $w_1 + w_2 = w_1' + w_2' = s$ y $w_i = w_i' \forall i > 2$, entonces $X\boldsymbol{w} = X\boldsymbol{w}'$, y por tanto su penalización bajo $J(\boldsymbol{w})$ solo depende del valor de $\|\boldsymbol{w}\|_2^2$ y $\|\boldsymbol{w}\|_1$. Tratemos de minimizar esto bajo la restricción de $w_1 + w_2 = s$, con el resto de entradas fijas.

$$\begin{aligned}\|\boldsymbol{w}\|_2^2 &= \sum_i w_i^2 \\ &= w_1^2 + w_2^2 + \sum_{i>2} w_i^2 \\ &= w_1^2 + (s - w_1)^2 + \sum_{i>2} w_i^2\end{aligned}$$

En este caso, hay solución única $w_1 = s/2 = w_2$. Por tanto, Ridge solo puede arrojar un único vector $\boldsymbol{w}$ que minimiza $J(\boldsymbol{w})$

$$\begin{aligned}\|\boldsymbol{w}\|_1 &= \sum_i |w_i| \\ &= |w_1| + |w_2| + \sum_{i>2} |w_i| \\ &\geq |w_1 + w_2| + \sum_{i>2} |w_i| \\ &= |s| + \sum_{i>2} |w_i|\end{aligned}$$

La igualdad se alcanza cuando w_1 y w_2 comparten signo, esto es, si $w_1 = ts, w_2 = (1-t)s$ para $t \in [0,1]$. Con esto, múltiples vectores $\boldsymbol{w}^*$ minimizan $J(\boldsymbol{w})$. Estos anulan una columna (x^1 o x^2) sii $w_1 = 0$ o $w_2 = 0$, esto es, $t = 0$ o $t = 1$. Sin embargo, aunque se puedan obtener distintos minimizadores $\boldsymbol{w}^*$, los valorespredichos $X\boldsymbol{w}^*$ sn los mismos para todos

(c) Reescalamiento de una característica

Reemplazamos una columna x^j por ax^j. Sea X' la matriz con esta característica modificada. Dado $\boldsymbol{w}$, queremos encontrar $\boldsymbol{w}'$ con $X\boldsymbol{w} = X'\boldsymbol{w}'$.

$$X\boldsymbol{w} = \sum_{i=1}^{D} x^i w_i = x^j w_j + \sum_{i \neq j} x^i w_i = a x^j w'_j + \sum_{i \neq j} x^i w_i = X\boldsymbol{w}'$$

$$\therefore w'_j = w_j / a$$

Con esto, las penalizaciones de x^j en L_1 y L_2 se convierten en

$$\begin{aligned}&\lambda_1 |w'_j| = \frac{\lambda_1}{a}|w_j| && \lambda_2 \|w'_j\|_2^2 = \frac{\lambda_2}{2a^2}\|w_j\|_2^2 \\ &L_1(\boldsymbol{w}') = \lambda_1 \sum_i |w'_i| && L_2(\boldsymbol{w}') = \frac{\lambda_2}{2}\sum_i w_i'^2 \\ &= \lambda_1 \sum_i |w_i| + \lambda_1 \frac{1-a}{a}|w_j| && = \frac{\lambda_2}{2}\sum_i w_i^2 + \lambda_2 \frac{1-a^2}{a^2} w_j^2 \\ &\therefore L_1(\boldsymbol{w}') = L_1(\boldsymbol{w}) + \lambda_1 \frac{1-a}{a}|w_j| && \therefore L_2(\boldsymbol{w}') = L_2(\boldsymbol{w}) + \lambda_2 \frac{1-a^2}{a^2} w_j^2\end{aligned}$$

Por tanto las penalizaciones cambian, y aunque $X\boldsymbol{w} = X'\boldsymbol{w}'$, puede que $\boldsymbol{w}'$ no sea óptimo. Además, cuando estamos connvirtiendo a unidades mas pequeñas, $a > 1$ entonces $\frac{1-a}{a} < 0$ y la penalización disminuye, mientras que si pasamos a unidades mas grandes, $a < 1$, y $\frac{1-a}{a} > 0$. Esto es, entre más grandes las unidades que se usen en una caracteística, la penalización aumenta

Si el factor de escalamiento a depende de los datos (p.e: $a = 1/\sigma$ al estandarizar), entonces solo puede depender de los datos de entrenamiento y no de los de testeo o validación para garantizar la integridad de los resultados obtenidos y que no estén dependiendo de datos que el modelo realmente no deberia tener acceso a la hora de entrenarse, basta con estimarlos en los datos de entrenamientos, y con ese valor hacer el reescalamiento en todas las particiones.

Al usar una conversión de unidades normal, a es una constante, por lo que no se tiene que estimar según la partición de los datos, no hay dependencia.

3 Problema 3. Probabilidades, ponderación y decisiones

(a) Pérdida logística

Con $z_n = \boldsymbol{x}_n^\top \boldsymbol{w} + b$ y $p_n = \sigma(z_n)$, el modelo Bernoulli es $Y_n \mid \boldsymbol{x}_n \sim \mathrm{Ber}(p_n)$, es decir $P(Y_n = y \mid \boldsymbol{x}_n) = p_n^y (1-p_n)^{1-y}$ con $y \in \{0, 1\}$. Por independencia condicional,

$$L(\boldsymbol{w}, b) = \prod_{n=1}^{N} p_n^{y_n} (1-p_n)^{1-y_n}, \qquad \ell(\boldsymbol{w}, b) = \log L = \sum_{n=1}^{N} \big[y_n \log p_n + (1-y_n) \log(1-p_n) \big].$$

Maximizar ℓ equivale a minimizar $-\frac{1}{N}\ell$, que es exactamente $J_{\log}$ en (3). Escribimos $J_{\log} = \frac{1}{N}\sum_n J_n$ con

$$J_n = -y_n \log \sigma(z_n) - (1-y_n) \log(1-\sigma(z_n)).$$

Como $\sigma(z) = (1+e^{-z})^{-1}$, se tiene $\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \sigma(z)(1-\sigma(z))$. Derivando J_n respecto a z_n:

$$\frac{dJ_n}{dz_n} = -y_n \frac{\sigma'(z_n)}{\sigma(z_n)} + (1-y_n) \frac{\sigma'(z_n)}{1-\sigma(z_n)} = -y_n(1-p_n) + (1-y_n)p_n = p_n - y_n.$$

Como $\partial z_n / \partial \boldsymbol{w} = \boldsymbol{x}_n$ y $\partial z_n / \partial b = 1$, la regla de la cadena da

$$\frac{\partial J_n}{\partial \boldsymbol{w}} = (p_n - y_n)\, \boldsymbol{x}_n, \qquad \frac{\partial J_n}{\partial b} = p_n - y_n.$$

Promediando sobre las muestras, y usando que $X^\top = [\boldsymbol{x}_1 \ \cdots \ \boldsymbol{x}_N]$ tiene a los $\boldsymbol{x}_n$ por columnas (de modo que $X^\top \boldsymbol{e} = \sum_n e_n \boldsymbol{x}_n$ para $\boldsymbol{e} \in \mathbb{R}^N$), con $\boldsymbol{e} = \boldsymbol{p} - \boldsymbol{y}$:

$$\nabla_{\boldsymbol{w}} J_{\log} = \frac{1}{N} \sum_{n=1}^{N} (p_n - y_n) \boldsymbol{x}_n = \frac{1}{N} X^\top (\boldsymbol{p} - \boldsymbol{y}) \in \mathbb{R}^D, \qquad \frac{\partial J_{\log}}{\partial b} = \frac{1}{N} \mathbf{1}_N^\top (\boldsymbol{p} - \boldsymbol{y}) \in \mathbb{R}.$$

En la parametrización aumentada $\boldsymbol{\theta} = (b, \boldsymbol{w}^\top)^\top$, con $\widetilde{X} = [\mathbf{1}_N \ X]$ y $\widetilde{X}^\top = \begin{pmatrix} \mathbf{1}_N^\top \\ X^\top \end{pmatrix}$,

$$\nabla_{\boldsymbol{\theta}} J_{\log} = \frac{1}{N} \widetilde{X}^\top (\boldsymbol{p} - \boldsymbol{y}) \in \mathbb{R}^{D+1}.$$

Sea $\tilde{\boldsymbol{x}}_n = (1, \boldsymbol{x}_n^\top)^\top$ la n-ésima fila de $\widetilde{X}$, de modo que $z_n = \tilde{\boldsymbol{x}}_n^\top \boldsymbol{\theta}$ y $\partial p_n / \partial \boldsymbol{\theta} = p_n(1-p_n)\tilde{\boldsymbol{x}}_n$. Derivando $\nabla_{\boldsymbol{\theta}} J_{\log} = \frac{1}{N}\sum_n (p_n - y_n)\tilde{\boldsymbol{x}}_n$:

$$\nabla^2_{\boldsymbol{\theta}} J_{\log} = \frac{1}{N} \sum_{n=1}^{N} p_n(1-p_n)\, \tilde{\boldsymbol{x}}_n \tilde{\boldsymbol{x}}_n^\top = \frac{1}{N} \widetilde{X}^\top S \widetilde{X} \in \mathbb{R}^{(D+1)\times(D+1)}, \qquad S = \mathrm{diag}\big(p_n(1-p_n)\big) \in \mathbb{R}^{N \times N}.$$

Para todo $\boldsymbol{v} \in \mathbb{R}^{D+1}$,

$$\boldsymbol{v}^\top \nabla^2 J_{\log}\, \boldsymbol{v} = \frac{1}{N} \sum_{n=1}^{N} p_n(1-p_n)\, (\tilde{\boldsymbol{x}}_n^\top \boldsymbol{v})^2 \ \geq 0,$$

pues $p_n(1-p_n) \in (0, \frac{1}{4}]$. El Hessiano es semidefinido positivo en todo $\boldsymbol{\theta}$, por lo que $J_{\log}$ es convexa.

Veamos cuando es estricta. Como $p_n(1-p_n) > 0$ para todo n, la forma cuadrática se anula sii $\widetilde{X}\boldsymbol{v} = 0$. Por tanto:

- $J_{\log}$ es estrictamente convexa sii $\operatorname{rank}\widetilde{X} = D+1$ (las columnas de X y el vector $\mathbf{1}_N$ son linealmente independientes; esto requiere $N \geq D+1$).
- Si $\lambda_2 > 0$ en (4), el Hessiano de F es $\nabla^2 J_{\log} + \lambda_2 P$, y $\boldsymbol{v}^\top \nabla^2 F\, \boldsymbol{v} = \frac{1}{N}\sum_n p_n(1-p_n)(\tilde{\boldsymbol{x}}_n^\top \boldsymbol{v})^2 + \lambda_2 \|\boldsymbol{v}_1\|_2^2$ con $\boldsymbol{v} = (v_0, \boldsymbol{v}_1)$. Esto se anula solo si $\boldsymbol{v}_1 = 0$ y $\widetilde{X}\boldsymbol{v} = v_0 \mathbf{1}_N = 0$, es decir $v_0 = 0$. Entonces F es estrictamente convexa aun cuando X no tenga rango completo (el término $\lambda_1\|\boldsymbol{w}\|_1$ es convexo y no afecta esto).

Ahora, convexidad no garantiza que el ínfimo se alcance (por ejemplo, e^x no tiene mínimo en $\mathbb{R}$). Las clases son perfectamente separables si existe $(\boldsymbol{w}_0, b_0)$, con $z_n^0 = \boldsymbol{w}_0^\top \boldsymbol{x}_n + b_0$, tal que $(2y_n - 1)z_n^0 > 0$ para todo n. Sea $\boldsymbol{\theta}_0 = (b_0, \boldsymbol{w}_0)$ y consideremos $\boldsymbol{\theta} = t\boldsymbol{\theta}_0$ con $t \to \infty$. Como $\log(1+e^{-z})$ es el término de la clase correcta, cada sumando de $J_{\log}$ es $\log\left(1 + e^{-t(2y_n-1)z_n^0}\right) \to 0$, y entonces $J_{\log} \to 0$. Pero cada sumando es estrictamente positivo para todo $\boldsymbol{\theta}$ finito, así que $J_{\log}(\boldsymbol{\theta}) > 0$ para todo $\boldsymbol{\theta}$. El ínfimo 0 no se alcanza: no existe un minimizador finito, y las sucesiones minimizantes cumplen $\|\boldsymbol{\theta}\| \to \infty$ (las probabilidades se saturan en 0 y 1). El Hessiano es definido positivo en cada punto (si $\operatorname{rank}\widetilde{X} = D+1$), pero se degenera cuando $p_n(1-p_n) \to 0$, de modo que la convexidad estricta no basta para tener existencia.

Como $-\log\sigma(z) = \log(1+e^{-z})$, $-\log(1-\sigma(z)) = \log(1+e^{z})$ y $\log(1+e^{-z}) = \log(1+e^{z}) - z$, entonces

$$J_n = y_n \log(1+e^{-z_n}) + (1-y_n)\log(1+e^{z_n}) = \log(1+e^{z_n}) - y_n z_n,$$

$$\boxed{J_{\log} = \frac{1}{N}\sum_{n=1}^{N}\big[\log(1+e^{z_n}) - y_n z_n\big].}$$

Evaluación estable para $|z|$ grande. Calcular $\log(1+e^z)$ directamente desborda para z grande ($e^{1000} = \infty$ en doble precisión). Usamos que

$$\log(1+e^z) = \max(z, 0) + \log\big(1 + e^{-|z|}\big)$$

en la cual el exponente $-|z|$ es siempre ≤ 0, y $\log(1+u)$ es preciso para u pequeño. Así,

$$J_n = \max(z_n, 0) - y_n z_n + \operatorname{log1p}\big(e^{-|z_n|}\big).$$

(b) Decisión sensible al costo

Sea $p = P(Y = 1 \mid \boldsymbol{x})$ la probabilidad verdadera. Con costos $C_{FP} = 1$, $C_{FN} = 12$ y costo cero para decisiones correctas, los costos condicionales esperados son

- *Alertar* (predecir 1): se paga C_{FP} solo si $Y = 0$, entonces $\mathbb{E}[\text{costo} \mid \boldsymbol{x}] = (1-p)\, C_{FP}$.
- *No alertar* (predecir 0): se paga C_{FN} solo si $Y = 1$, entonces $\mathbb{E}[\text{costo} \mid \boldsymbol{x}] = p\, C_{FN}$.

La regla que minimiza el costo esperado es alertar sii $(1-p)C_{FP} \leq p\, C_{FN}$, es decir

$$p \;\geq\; \tau^\star = \frac{C_{FP}}{C_{FP} + C_{FN}} = \frac{1}{13} \approx 0{,}0769.$$

Caso $p = 0.10$. Alertar cuesta $0.9 \times 1 = 0.9$ y no alertar cuesta $0.10 \times 12 = 1.2$. La decisión óptima es **alertar** (ahorra 0.3 por caso en promedio). Con $\tau = 0.5$, como $0.10 < 0.5$, la regla *no* alertaría y pagaría 1.2 en lugar de 0.9. El umbral 0.5 es óptimo solo cuando $C_{FP} = C_{FN}$.

El umbral $\tau^\star$ depende únicamente de los costos de los dos tipos de error. La fracción de casos con alerta es $P\big(p(\boldsymbol{X}) \geq \tau^\star\big)$, que depende de cómo se distribuyen las probabilidades $p(\boldsymbol{x})$ en la población y puede ser grande (si muchos casos tienen $p > 1/13$, se alerta a muchos). Un límite de

capacidad es una restricción adicional: habría que ordenar los casos por $p(\boldsymbol{x})$ y alertar solo a los K primeros, lo que equivale a usar un umbral efectivo mayor que $\tau^\star$, y esa decisión ya no minimiza el costo esperado sin restricciones.

(c) Ponderación de clases

Fijamos $\boldsymbol{x}$ y consideramos $\mathcal{R}(q) = -a_1 p \log q - a_0(1-p)\log(1-q)$ con $a_0, a_1 > 0$ y $0 < p, q < 1$. Derivando,

$$\mathcal{R}'(q) = -\frac{a_1 p}{q} + \frac{a_0(1-p)}{1-q} = 0 \implies a_1 p(1-q) = a_0(1-p)q \implies \boxed{q^\star = \frac{a_1 p}{a_1 p + a_0(1-p)}} \in (0,1).$$

Como $\mathcal{R}''(q) = \frac{a_1 p}{q^2} + \frac{a_0(1-p)}{(1-q)^2} > 0$, $\mathcal{R}$ es estrictamente convexa y $q^\star$ es su único minimizador.

$q^\star = p \iff a_1 = a_1 p + a_0(1-p) \iff a_1(1-p) = a_0(1-p)$, y como $p < 1$, esto ocurre sii $a_1 = a_0$. Podemos expresaresto en términos de los odds:

$$\frac{q^\star}{1-q^\star} = \frac{a_1}{a_0} \cdot \frac{p}{1-p},$$

es decir, la ponderación multiplica los momios verdaderos por a_1/a_0. Solo con pesos iguales el minimizador es la probabilidad verdadera (calibrada).

En general no es correcto usar los resultados del literal anterior para q^*, pues el umbral $1/13$ del inciso (b) es una condición sobre la probabilidad verdadera p, y $q^\star \neq p$ si $a_1 \neq a_0$. Umbralizar $q^\star$ en un valor t equivale a umbralizar p mediante

$$q^\star \geq t \iff \frac{p}{1-p} \geq \frac{a_0}{a_1} \cdot \frac{t}{1-t}.$$

Si se entrena con $a_1 = C_{FN} = 12$, $a_0 = C_{FP} = 1$ y se umbraliza $q^\star$ en $t = 0.5$, la condición es $\frac{p}{1-p} \geq \frac{1}{12}$, es decir $p \geq 1/13$, que es exactamente la regla óptima del inciso (b): los pesos ya incorporan los costos. Si además se umbralizara en $1/13$, los costos se contarían dos veces. Si los pesos se eligieron por otra razón (por ejemplo, balancear clases), se recupera p con $\frac{p}{1-p} = \frac{a_0}{a_1}\frac{q}{1-q}$ antes de aplicar el umbral de costo.

Ahora, $q^\star$ es el minimizador puntual del riesgo poblacional sobre *todas* las funciones de $\boldsymbol{x}$, usando la $p(\boldsymbol{x})$ verdadera. En la práctica:

- *Muestra finita:* se minimiza el riesgo empírico, una estimación ruidosa del poblacional, así que $\hat{q}$ fluctúa alrededor de $q^\star$; y si las clases son separables, $\hat{q} \to 0$ o 1 y no existe minimizador finito (inciso (a)).
- *Modelo restringido:* la regresión logística es lineal en el logit. Si el $\operatorname{logit} p(\boldsymbol{x})$ verdadero no es lineal en $\boldsymbol{x}$, el minimizador dentro del modelo es solo la mejor aproximación lineal bajo la pérdida ponderada, y los pesos cambian *cuál* aproximación se obtiene, no solo un corrimiento en los momios.
- *Regularización:* la penalización encoge los coeficientes (compromiso sesgo–varianza) y acerca las predicciones a la tasa base, por lo que son menos extremas y en general quedan descalibradas aun con $a_0 = a_1$.

Por tanto, $q^\star$ y $\tau^\star$ describen el objetivo ideal; en la práctica se verifica la calibración y el umbral final se elige con datos de validación.